



Universidad Politécnica Metropolitana de Hidalgo
Fundamentos de Inteligencia Artificial

**“Ingeniería de Clasificación de Riesgo en
Neurofibromatosis Tipo 1 (NF1) basada en Características
Clínicas: mediante Ensemble Learning”**

Maestría en Inteligencia Artificial

Dr. Efrén Juárez Castillo

Jéssica Melani Romero Lora

Pareja-4A-Clasificación.py

Para la elaboración del proyecto se empleó la base de datos estructurada “NF1”, perteneciente al dominio de salud y medicina en Turquía. La información proviene de los Institutos Nacionales de Salud especializados en Neurofibromatosis (NIH-NF1). La base de datos recopila características clínicas asociadas a la Neurofibromatosis Tipo 1 (NF1), incluyendo antecedentes familiares, presencia y tipología de tumores, parámetros morfológicos (tamaño, color y forma), así como otros problemas neurológicos derivados de la enfermedad.

El repositorio fue obtenido del Repositorio de Aprendizaje Automático de la Universidad de California en Irvine (UCI) bajo el título “*Neurofibromatosis Tipo 1: Síntomas Clínicos de Casos Familiares y Esporádicos*”. La Neurofibromatosis Tipo 1 (NF1) es un desorden

progresivo multisistémico de herencia autosómica dominante que presenta múltiples manifestaciones neurológicas.

Se estima que únicamente entre el 30% y el 50% de los casos alcanzan un nivel de severidad significativo. En la actualidad no existen biomarcadores ni criterios clínicos simples que permitan predecir con certeza qué pacientes desarrollarán un MPNST (Tumor Maligno de la Vaina Nerviosa Periférica) o un astrocitoma sintomático en etapas tempranas. La necesidad médica identificada es el desarrollo de una herramienta objetiva de estratificación de riesgo.

Clasificar a un paciente como de Alto Riesgo (1) permitiría a los médicos intensificar la vigilancia clínica (por ejemplo, mediante resonancias magnéticas anuales) y planificar una intervención temprana, lo que se traduciría en una mejora sustancial de los resultados clínicos. Los criterios de diagnóstico clínico tradicionales se basan en esquemas lineales (sí/no), lo cual limita su capacidad predictiva.

En contraste, un modelo de Ensemble Learning como *Random Forest* puede capturar las interacciones no lineales y complejas entre múltiples síntomas por ejemplo, la combinación de la edad de diagnóstico, la presencia de neurofibromas plexiformes y el historial familiar, relaciones que resultan imposibles de modelar de manera manual.

En un entorno médico la robustez de los modelos es un requisito esencial, ya que la confianza en los resultados diagnósticos depende de su estabilidad. La ingeniería de modelos garantiza esta robustez mediante la selección de características con técnicas como LASSO o Random

Forest, las cuales reducen el ruido en el conjunto de datos y evita el sobreajuste a información irrelevante, disminuyendo la varianza; la validación cruzada estratificada con $K=5$ evalúa rigurosamente la capacidad de generalización en subconjuntos no vistos; y la cuantificación de la estabilidad a través de la desviación estándar de la métrica AUC (σ) constituye la prueba fundamental de que el modelo produce resultados consistentes, minimizando la varianza y maximizando la confiabilidad clínica.

1. Diccionario de Datos (*Data Dictionary*)

Nombre	Descripción	Tipo de variable
--------	-------------	------------------

Case Type	Tipo general de caso de estudio o cohorte.	Generalmente utilizada para diferenciar grupos dentro del estudio (p. ej., control vs. paciente, o Fibromatosis tipo NF1 vs. tipo NF2).
Tumour Case	Variable objetivo (Y). Clasificación de la gravedad/ complicación tumoral.	Binaria (1 = Alto Riesgo/ Complicación Severa (MPNST - Tumor agresivo). 0 = Bajo Riesgo / Sin complicación)
Age of Mother	Edad de la madre en un punto de referencia (p. ej., nacimiento del paciente).	Numérica Continua (Escalada normalizada entre 0 y 1. Puede indicar un factor genético o de historial.)
Age of Father	Edad del padre en un punto de referencia.	Numérica Continua (Escalada normalizada entre 0 y 1. Puede indicar un factor genético o de historial.)
Age at First Diagnosis	Edad del paciente cuando se realizó el primer diagnóstico de NF.	Numérica Continua (Escalada - factor clínico temporal crucial en el pronóstico.)
Café au Lait (CAL)	Presencia de manchas "café con leche" en la piel.	Binaria (Criterio diagnóstico clave 1=Sí, 0=No).
Axillary Freckles	Presencia de pecas en las	Binaria (Criterio

2

	axilas.	diagnóstico clave 1=Sí, 0=No).
Inguinal Freckles	Presencia de pecas en la ingle.	Binaria (Criterio diagnóstico clave 1=Sí, 0=No).
Lisch Nodules	Presencia de hamartomas en el iris.	Binaria (Criterio diagnóstico clave 1=Sí, 0=No).
Dermal Neurofibromas	Presencia de neurofibromas cutáneos benignos.	Binaria (Manifestación común de NF1).

Plexiform Neurofibromas	Presencia de neurofibromas plexiformes (tumores grandes, a menudo profundos).	Binaria (Factor de riesgo crucial. Se consideran precursores de MPNST.)
Optic Glioma	Presencia de un tumor en el nervio óptico.	Binaria (Complicación seria de NF1 1=Sí, 0=No).
Skeletal Dysplasia	Presencia de anomalías óseas (displasia esquelética).	Binaria (Manifestación ósea de NF1 1=Sí, 0=No).
Learning Disability	Presencia de discapacidad de aprendizaje.	Binaria (Comorbilidad neurocognitiva común en NF1 1=Sí, 0=No)
Hypertension	Presencia de hipertensión arterial.	Binaria (Complicación cardiovascular asociada a NF1 1=Sí, 0=No).
Astrocytoma	Presencia de un tumor cerebral o espinal (astrocitoma).	Binaria (Complicación tumoral grave 1=Sí, 0=No).
Hamartoma	Presencia de un crecimiento tisular no canceroso desorganizado (no glioma ni neurofibroma).	Binaria (Lesión benigna 1=Sí, 0=No).
Scoliosis	Presencia de curvatura anormal de la columna vertebral.	Binaria (Manifestación esquelética común 1=Sí, 0=No)

3

Other Symptoms	Presencia de otros síntomas no listados explícitamente.	Binaria (Variable "comodín" para condiciones secundarias (1=Sí, 0=No)
-----------------------	---	---

II. Desarrollo técnico: Explicación detallada del pipeline

El proyecto siguió un riguroso *pipeline* de ciencia de datos orientado a la clasificación de riesgo, con énfasis en garantizar la robustez y la capacidad de generalización del modelo final, estableciendo ambas propiedades como prioritarias durante el diseño y la evaluación de las métricas de desempeño. A lo largo del desarrollo, se definieron el formato y los estándares técnicos necesarios para asegurar resultados óptimos,

considerando tanto la calidad de los datos como la pertinencia de las variables seleccionadas.

En este sentido, cada fase del *pipeline* fue ejecutada con justificaciones específicas, desde la preparación y depuración de los datos hasta la selección de variables, cuyo objetivo fue asegurar la solidez del modelo y minimizar el ruido que pudiera afectar la interpretación de los resultados finales. Asimismo, se buscó incrementar el poder predictivo y discriminatorio de los algoritmos, reduciendo la complejidad del modelo elegido y optimizando su desempeño.

De manera complementaria, se implementaron estrategias para mitigar el riesgo de sesgo y disminuir la varianza en cada modelo evaluado, garantizando que las métricas obtenidas reflejaran un equilibrio entre precisión y capacidad de generalización. Este enfoque permitió no solo mejorar la calidad técnica del proyecto, sino también asegurar que los resultados fueran consistentes y aplicables en escenarios reales de clasificación de riesgo.

I. Preprocesamiento y Análisis Exploratorio de Datos

El objetivo de esta fase fue llevar a cabo las tareas de preparación de la base de datos para el entrenamiento y testeo de modelos de *Machine Learning*, asegurando que el formato y la calidad fueran óptimos para los algoritmos comparados (Regresión

4

Lineal, Árbol de Decisión y XG Boost). En este sentido, se ejecutaron procesos de limpieza, escalamiento, normalización de nombres y división estratificada, con el propósito de garantizar la consistencia y reproducibilidad de los experimentos.

```
# Visualización de las columnas del dataset  
df.head(10)
```

	CaseType	Tumour_Case	AgeofMother	AgeofFather	AgeatFirstDiagnosis	CafaultaitCLS	AxillaryFreckles	InguinalFreckles
0	0	1	0.482759	0.279070	0.074380	0	0	0
1	0	1	0.209897	0.232568	0.107438	1	1	0
2	1	1	0.413793	0.162791	0.140496	1	1	0
3	0	1	0.482759	0.348837	0.140496	1	1	0
4	0	1	0.379310	0.348837	0.008264	1	1	1
5	0	1	0.596207	0.495116	0.041322	1	0	0
6	0	1	0.596207	0.348837	0.057851	1	1	0
7	0	1	0.275862	0.348837	0.041322	1	1	1
8	1	1	0.275862	0.162791	0.140496	0	0	0
9	1	0	0.596207	0.767642	0.338843	0	0	0

Durante el desarrollo de esta primera etapa se evaluó el estado inicial del *dataset*, el cual presentaba condiciones casi ideales: no contenía valores nulos y las variables relacionadas con la edad de los pacientes (“Age of Mother” o Edad de la Madre, “Age of Father” o Edad del Padre, “Age of First Diagnosis” o Edad del primer diagnóstico) ya se encontraban en formato *float64* y escaladas mediante *MinMaxScaler* en un rango entre 0 y 1.

```

# Importación de librerías base para comenzar con el tratamiento de limpieza y exploración de datos (EDA)
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Lectura de la base de datos a partir del RAW de GitHub
url_github = 'https://raw.githubusercontent.com/Fun-datasets/refs/heads/main/neurofibromatosis.csv'

# Transformación a dataframe a partir de la lectura del archivo de GitHub mediante un link
df = pd.read_csv(url_github)

# Exploración del dataset y status de las variables
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 296 entries, 0 to 295
Data columns (total 19 columns):
 #   Column                                Non-Null Count  Dtype
---  -
 0   Case Type                            296 non-null    int64
 1   Tumour Case                          296 non-null    int64
 2   Age of Mother                        296 non-null    float64
 3   Age of Father                        296 non-null    float64
 4   Age at First Diagnosis                296 non-null    float64
 5   Café au lait (CLS)                   296 non-null    int64
 6   Axillary Freckles                    296 non-null    int64
 7   Inguinal Freckles                    296 non-null    int64
 8   Lisch Nodules                        296 non-null    int64
 9   Dermal Neurofibromins                 296 non-null    int64
10  Plexiform Neurofibromins              296 non-null    int64
11  Optic Glioma                          296 non-null    int64
12  Skeletal Dysplasia                    296 non-null    int64
13  Learning Disability                   296 non-null    int64
14  Hypertension                          296 non-null    int64
15  Astrocytoma                          296 non-null    int64
16  Hamartoma                            296 non-null    int64
17  Scoliosis                            296 non-null    int64
18  Other Symptoms                       296 non-null    int64
dtypes: float64(3), int64(16)

```

5

Esta preparación previa permitió reducir significativamente la necesidad de transformaciones adicionales y facilitó la integración de los datos en los modelos seleccionados. Al respecto, los autores de la base de datos señalan las técnicas de limpieza aplicadas y la disponibilidad del conjunto de datos bajo dichas condiciones, lo que respalda la validez y confiabilidad del material utilizado en su publicación “*Un enfoque de aprendizaje automático para predecir casos de enfermedades familiares y esporádicas basándose en síntomas clínicos: introducción de un nuevo conjunto de datos*”, publicada en el *Boletín Turco de Higiene y Biología Experimental* (2025) por Sharafi, Parisa et al., 1

No obstante, pese a las cualidades de la base de datos, fue necesario aplicar una normalización programática de los nombres de las columnas con el fin de evitar errores de sintaxis y garantizar la compatibilidad en el entorno de trabajo de Google Colab. Estos ajustes se reflejan, por ejemplo, en la variable “Café au Lait” (CLS), que fue modificada a *Cafe_au_Lait*, siguiendo convenciones de nomenclatura más estandarizadas y adecuadas para la manipulación.

```

# Importación de las librerías
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import GridSearchCV
import numpy as np

# Ajuste Rápido de Nombres de Columnas: Eliminar espacios y caracteres especiales
df.columns = df.columns.str.replace(r"[A-Za-z0-9_]+", '', regex=True) # Esta instrucción elimina (),/ etc.
df.columns = df.columns.str.replace(r"\s+", '', regex=True) # Con esta función eliminamos posibles espacios

# Renombrar variables clave para asegurar uniformidad
df.rename(columns={'TumourCase': 'Tumour_Case',
                  'CafeauLaitCLS': 'Cafe_au_Lait'},
          inplace=True)

```

Por otra parte, la división del *dataset* en conjuntos de entrenamiento (80%) y prueba (20%) fue ejecutada utilizando el parámetro **stratify=y** dentro de la función **train_test_split**. El desbalance de las clases se presentó al observar la variable objetivo (**Tumour_Case**), la cual representó una complicación severa menos frecuente que los casos sin tumor. Esto genera un desbalance de clases en el *dataset*.

6

Debido a esto se optó por utilizar **stratify=y**, con el objetivo de garantizar que la proporción de pacientes con tumor (clase positiva) y sin tumor (clase negativa) sea idéntica en el conjunto de entrenamiento y en el conjunto de prueba.

División estratificada:

```
# 1. Separar X e y
# y = Tumour_Case (nuestra variable objetivo: Complicación Tumoral Severa)
y = df['Tumour_Case']

# X = Todas las demás, EXCEPTO 'Tumour_Case' y 'CaseType'!
X = df.drop(['Tumour_Case', 'CaseType'], axis=1)
print(f"Features iniciales listas para la Fase de Feature Engineering: {X.shape[1]} columnas.")

Features iniciales listas para la Fase de Feature Engineering: 17 columnas.

# 2. División Estratificada (80% Entrenamiento, 20% Prueba)
# Stratify=y es VITAL para el desbalance de clases y la estabilidad.
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
                                                    stratify=y, random_state=42)
print("Datos divididos y listos para el entrenamiento.")

Datos divididos y listos para el entrenamiento.

# Importación de librerías para seleccionar variables altamente correlacionadas:
import seaborn as sns
import matplotlib.pyplot as plt

# 1. Generar la Matriz de Correlación (en el set de entrenamiento)
corr_matrix = X_train.corr().abs()

# 2. Identificar pares de variables altamente correlacionadas (umbral |0.9|)
upper = corr_matrix.where(np.triu(np.ones(corr_matrix.shape), k=1).astype(bool))
to_drop_highly_correlated = [column for column in upper.columns if any(upper[column] > 0.9)]

print("— Análisis de Correlación —")
print(f"Features con alta correlación (>|0.9|) y que deben eliminarse: {to_drop_highly_correlated}")

— Análisis de Correlación —
Features con alta correlación (>|0.9|) y que deben eliminarse: []

# Visualización para el reporte
plt.figure(figsize=(12, 18))
sns.heatmap(corr_matrix, annot=False, cmap='coolwarm')
plt.title('Matriz de Correlación Absoluta')
plt.show()
```

2. Impacto en la Estabilidad del Modelo

Al replicar la distribución de la clase en ambos conjuntos, se evita que el modelo de entrenamiento se sesgue por un desequilibrio accidental, asegurando que aprenda las características de ambas clases de manera proporcional.

Más importante aún, se garantiza que el conjunto de pruebas sea un reflejo del problema de clasificación real. Esto hace que las métricas finales (AUC, Recall) sean

un indicador confiable y robusto de la capacidad de generalización del modelo. Si el modelo falla en el conjunto de prueba, sabemos que es un problema de *performance* y no de una distribución de datos sesgada.

II. Selección de características o “*Feature Selection*”

Durante el desarrollo de esta fase se aplicaron técnicas de reducción de

dimensionalidad y análisis de colinealidad entre variables, con el objetivo de controlar la varianza de los modelos considerados para la etapa final de evaluación de métricas de rendimiento.

Este enfoque permitió identificar relaciones lineales y no lineales que pudieran comprometer la estabilidad del modelo, así como redundancias que afectaran su capacidad de generalización. El requisito metodológico para esta etapa consistió en emplear al menos dos procedimientos distintos de diagnóstico, con el fin de garantizar una validación más robusta en la detección de redundancias y otros comportamientos problemáticos en las variables.

Entre las técnicas utilizadas se incluyeron métodos estadísticos tradicionales, Lasso Regression (LR), utilizada como método de regularización para penalizar coeficientes irrelevantes y favorecer la selección de variables más significativas; y Random Forest (RF), aplicado como técnica de importancia de variables, capaz de detectar interacciones y relaciones no lineales entre los predictores.

La combinación de ambos métodos permitió obtener una visión integral del comportamiento de las variables, reduciendo el riesgo de sesgo y varianza, y asegurando que los modelos seleccionados se construyeran sobre un conjunto de datos depurado y técnicamente consistente.


A. Análisis Estadístico (Matriz de correlación)

El propósito de usar esta herramienta fue evaluar la redundancia entre las *features* o variables antes de la etapa de modelado (Fase 3). Durante esta etapa se generó una matriz de correlación para identificar pares de variables con alta correlación en donde ($p > |0.9|$).

8

Durante la obtención de los resultados se observó la ausencia de colinealidad fuerte entre las variables, confirmando que las variables candidatas a la fase 3 de modelado eran estadísticamente significativas e independientes, lo cual garantizó que el subconjunto final de entrenamiento no introduciría multicolinealidad artificial, esta tarea fue clave para asegurar la estabilidad de las métricas del modelo lineal de regresión logística (RL).

B) Métodos de Selección de Variables (LASSO y Random Forest)



9

Para la selección de variables, el objetivo principal fue asegurar la robustez del modelo y minimizar el ruido que pudiera afectar la interpretación de los resultados finales. Asimismo, se buscó incrementar su capacidad predictiva y discriminante, con el fin de reducir la complejidad del modelo elegido y optimizar su desempeño.

➔ **Método Lasso (L1 - Regularización):** este método de tipo lineal basado en la selección del coeficiente se utilizó para encontrar el subconjunto de variables con la mayor estabilidad lineal. El método realizó un ajuste del hiper parámetro C mediante Grid Search, logrando forzar a los coeficientes de las variables con menor valor predictivo a cero, esto le permitió actuar como una especie de filtro de baja varianza.

```
# 1. Definir el modelo con penalización L1 y GridSearchCV para encontrar el mejor C
lasso_model = LogisticRegression(penalty='l1', solver='liblinear',
                                random_state=42, class_weight='balanced', max_iter=1000)
```

```
# Rango de C (C bajo = Alta Regularización = Más coeficientes a cero)
param_grid_lasso = {'C': np.logspace(-3, 2, 6)} # [0.001, 0.01, 0.1, 1, 10, 100]

grid_search_lasso = GridSearchCV(lasso_model, param_grid_lasso, cv=5,
                                scoring='f1', verbose=0)
grid_search_lasso.fit(X_train, y_train)
```

```
***
> GridSearchCV
> best_estimator_:
  > LogisticRegression
  |
```

```
# Extraer coeficientes no nulos del mejor modelo
best_lasso = grid_search_lasso.best_estimator_
lasso_coef = pd.Series(best_lasso.coef_[0], index=X_train.columns)
```

```
# Seleccionar features con coeficiente ABSOLUTO > 0.001
selected_lasso_features = lasso_coef[abs(lasso_coef) > 1e-3].index.tolist()
```

```
print("\n--- Resultados LASSO (L1 Regularización) ---")
print(f"Features seleccionadas por LASSO ({len(selected_lasso_features)}): {selected_lasso_features}")
```

```
--- Resultados LASSO (L1 Regularización) ---
Features seleccionadas por LASSO (3): ['CafaultCLS', 'OpticGlioma', 'OtherSymptoms']
```

→ Método Random Forest: a diferencia de Lasso, este método no lineal se utilizó para medir la contribución de cada feature a la reducción de la impureza (Coeficiente de Gini), identificando las variables con el mayor poder discriminatorio en un entorno no

10

lineal.

Método 2: Importancia de Características por Árboles (Random Forest)

```
# 1. Entrenar un modelo RF base (solo para la importancia)
rf_selector = RandomForestClassifier(n_estimators=100, random_state=42,
                                   class_weight='balanced', max_depth=10)
rf_selector.fit(X_train, y_train)
```

```
RandomForestClassifier
RandomForestClassifier(class_weight='balanced', max_depth=10, random_state=42)
```

```
# 2. Extraer la importancia y ordenar
rf_importance = pd.Series(rf_selector.feature_importances_, index=X_train.columns).sort_values(ascending=False)
```

```
# 3. Definir un umbral (ej. seleccionar todas las features cuya importancia sea mayor a la media)
mean_importance = rf_importance.mean()
selected_rf_features = rf_importance[rf_importance > mean_importance].index.tolist()
```

```
print("\n--- Resultados Random Forest (Importancia de Features) ---")
print(f"Features seleccionadas por RF ({len(selected_rf_features)}): {selected_rf_features}")
```

```
--- Resultados Random Forest (Importancia de Features) ---
Features seleccionadas por RF (5): ['OpticGlioma', 'OtherSymptoms', 'AgeatFirstDiagnosis', 'AgeofFather', 'AgeofMother']
```

→ Subconjunto Final: Este es un método de intersección enfocado en el subconjunto

final, el cual se definió como la intersección de las *features* seleccionadas por ambos métodos. Esta estrategia de doble filtro garantiza que el conjunto final sea robusto (bajo ruido) y altamente predictivo (alto poder discriminatorio), reduciendo la complejidad del modelo.

Subconjunto final y preparación pre- etapa 3

```
# Tomamos la Intersección (features que AMBOS métodos consideran relevantes)
set_lasso = set(selected_lasso_features)
set_rf = set(selected_rf_features)
```

```
# Actualizamos los sets de datos con el subconjunto final de features
FINAL_FEATURES = list(set_lasso.intersection(set_rf))
```

```
# Imprimir los resultados finales para iniciar el entrenamiento
print(f"Features Finales para el Entrenamiento ({len(FINAL_FEATURES)}):")
print(FINAL_FEATURES)
```

```
Features Finales para el Entrenamiento (2):
['OpticGlioma', 'OtherSymptoms']
```

III. Modelado y Validación Cruzada

El enfoque para esta etapa se centró en la comparación de estabilidad de resultados entre los tres modelos seleccionados (LR, RF y XG Boost), cumpliendo con los requisitos de la Fase 3 (usar 3 algoritmos distintos y $K = 5$ CV) y Fase 4 incluir las

11

métricas de promedio y desviación estándar (std) por modelo para realizar una comparación del rendimiento de las métricas.

1. Preparación para la Validación Cruzada Estratificada

```
# Importación de librerías
from sklearn.model_selection import StratifiedKFold
from sklearn.metrics import roc_auc_score, f1_score, recall_score, precision_score
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline
# Importación de modelos:
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
import xgboost as xgb
```

```
# Define la Validación Cruzada Estratificada (K=5)
N_SPLITS = 5
skf = StratifiedKFold(n_splits=N_SPLITS, shuffle=True, random_state=42)
```

```
# Inicialización del DataFrame vacío que recolectará TODOS los resultados (15 filas)
results_df = pd.DataFrame(columns=['Model', 'Fold', 'AUC', 'F1_Score', 'Recall'])
```

Implementación Algorítmica: De acuerdo con las instrucciones brindadas se eligieron tres algoritmos que representan distintos puntos en la búsqueda de la unión entre el Sesgo y la Varianza (*B/V Trade-Off*).

Los algoritmos son:

- 1) **Regresión Logística (RL):** Alto Sesgo / Baja Varianza (Línea Base Lineal).
- 2) **Random Forest (RF):** Sesgo y Varianza Balanceados (Potenciada por *Bagging*).
- 3) **XG Boost (XGB):** Bajo Sesgo / Alto Potencial de Varianza (Potenciada por *Boosting*).

La elección de cada uno de ellos se realizó con base en la revisión de la literatura sobre Neurofibromatosis del tipo NF1, con el objetivo de conocer de primera mano los resultados a partir del conjunto de datos. Posteriormente, se realizó una metodología complementaria de validación de los parámetros más importantes para cada algoritmo.

B) Metodología de Validación Implementada:

12

Hiperparámetros: Se utilizó Grid Search CV para optimizar los parámetros clave de cada modelo, posteriormente se utilizó validación cruzada con una implementación de Stratified Fold(n_splits=5) como se solicitó en las instrucciones del proyecto. Esto aseguró que la proporción de la variable objetivo (Tumour_Case) se mantuviera constante en cada uno de los 5 *folds* del entrenamiento, lo cual es vital para obtener métricas de estabilidad imparciales en el caso de desbalance de clases.

1. División y Entrenamiento por *Fold*: Implementación de folds (k) =5

```
# Importación de librerías
from sklearn.model_selection import StratifiedKFold
from sklearn.metrics import roc_auc_score, f1_score, recall_score, precision_score
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline
# Importación de modelos:
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
import xgboost as xgb

# Define la Validación Cruzada Estratificada (K=5)
N_SPLITS = 5
skf = StratifiedKFold(n_splits=N_SPLITS, shuffle=True, random_state=42)

# Inicialización del DataFrame vacío que recolectará TODOS los resultados (15 filas)
results_df = pd.DataFrame(columns=['Model', 'Fold', 'AUC', 'F1_Score', 'Recall'])
```

En esta etapa, la línea de código (bucle) for fold_n, (train_index, test_index) in enumerate(skf.split(X_train_final, y_train)) se ejecuta cinco veces para cada modelo

(RL, RF, XG Boost). Con el propósito de simular el rendimiento del modelo en diferentes escenarios de datos, midiendo así su estabilidad (varianza).

Dentro de cada iteración del bucle se completa:

1. **División Estratificada:** Los índices (`train_index`, `test_index`) generados por Stratified Fold dividen el conjunto de entrenamiento total de `X_train` en un subconjunto de entrenamiento del *fold* y un subconjunto de validación del *fold* `X_val`.

Esta división asegura que la proporción de casos de tumor se mantenga en el subconjunto de validación, lo cual es crucial para la evaluación imparcial de métricas como el Recall en casos de desbalance.

13

2. **Ajuste del Modelo:** El modelo (`best_model`) es ajustado (entrenado) exclusivamente con el subconjunto de entrenamiento del *fold*.
3. **Cálculo de Métricas (Medición de Estabilidad)**

Una vez entrenado, el modelo predice los resultados en el subconjunto de validación `X_val` el cual es completamente invisible para el modelo durante esa iteración. Las métricas AUC, F1-Score y Recall se calculan.

Evidencia de Estabilidad: El resultado de esta fase es la Tabla de 15 *Folds*, donde se observa que el Recall para la Regresión Logística es 1.00 en casi todos los *folds*, pero cae a 0.923077 en el *Fold* 5. Esta pequeña variación es capturada precisamente por la Desviación Estándar ($\sigma = 0.0344$ en el Recall), que es la justificación principal para la elección final del modelo.

Implementación del Primer Bucle del Pipeline de Grid Search CV (Mejor hiper parámetro):

Implementación del Segundo Bucle del Pipeline de Grid Search CV (Mejor modelo encontrado):

La Lógica de Anidación (Control de Flujo en los Folds)

El aspecto más importante, que resolvimos previamente, es el flujo de control. El bucle de *folds* está correctamente anidado dentro del bucle principal de modelos en la línea de código: `(for name, ... in models:)`.

1. **Ejecución Triple:** El proceso completo de 5 *folds* se repite tres veces, una por cada modelo (RL, RF, XGBoost). En donde $5 \times 3 = 15$. Donde 3 = LR, RF, XG Boost. 2.

Almacenamiento Acumulativo: Al final de los 5 *folds* de cada modelo, la línea `results_df = pd.concat([...])` añade los 5 resultados al *DataFrame* global, lo que permite la tabulación final de los 15 resultados sin sobrescribir los datos de los modelos anteriores o sobrescribir las métricas de uno de ellos.

```

+ %*.Ejecutando Grid Search y Evaluación para RL* %*.
Mejores parámetros para RL: {'rl__C': np.float64(0.1)}

+ %*.Ejecutando Grid Search y Evaluación para RF* %*.
/tmp/.python-input-288079995.py:62: FutureWarning: The behavior of DataFrame concatenation with empty or all-NA entries is deprecated.
  results_df = pd.concat([results_df, pd.DataFrame(fold_results_list)], ignore_index=True)
Mejores parámetros para RF: {'rf__max_depth': 5, 'rf__n_estimators': 100}

+ %*.Ejecutando Grid Search y Evaluación para XGB* %*.
Mejores parámetros para XGB: {'xgb__learning_rate': 0.05, 'xgb__max_depth': 3, 'xgb__n_estimators': 100}

```

La Tabla Comparativa de Métricas de Estabilidad es el producto final del *pipeline* de validación Cruzada Estratificada y sirve como la prueba de fuego para seleccionar el modelo operativo. El análisis se enfoca en el Promedio (Mean) como indicador de Rendimiento (Bajo Sesgo) y la Desviación Estándar como indicador de Estabilidad (Baja Varianza).

El Poder Discriminatorio General, medido por el AUC Mean, demuestra que el *Feature Engineering* ha sido altamente efectivo, ya que los tres modelos presentan un rendimiento sobresaliente, concentrándose alrededor de 0.94. XG Boost (0.9449) exhibe el promedio más alto, seguido muy de cerca por Random Forest (0.9441) y la Regresión Logística (0.9437).

```
# 2. Generación de la Tabla Comparativa Final
print("\n★ * ° ● * ° ☆ ★ * ° ● * ° ☆ ★ * ° ● * ° ☆ Resultados detallados por fold")
print(results_df)
```

Model	Fold	AUC	F1_Score	Recall	
0	RL	1	0.947253	0.742857	1.000000
1	RL	2	0.966063	0.812500	1.000000
2	RL	3	0.997738	0.838710	1.000000
3	RL	4	0.954751	0.838710	1.000000
4	RL	5	0.852941	0.705882	0.923077
5	RF	1	0.958242	0.787879	1.000000
6	RF	2	0.957014	0.827586	0.923077
7	RF	3	0.986425	0.896552	1.000000
8	RF	4	0.929864	0.769231	0.769231
9	RF	5	0.889140	0.687500	0.846154
10	XGB	1	0.938462	0.787879	1.000000
11	XGB	2	0.957014	0.800000	0.923077
12	XGB	3	0.977376	0.785714	0.846154
13	XGB	4	0.959276	0.769231	0.769231
14	XGB	5	0.892534	0.727273	0.923077

En este sentido, la diferencia marginal entre estos valores (entre el mejor y el peor promedio) sugiere que, para los datos de la NF del tipo NF1, **la complejidad del**

modelo aporta poco valor al rendimiento general; por lo tanto, la decisión de selección debe pivotar hacia la confiabilidad (Linear Regression - LR).

No obstante, la desviación estándar es la medida de la variabilidad de las métricas a través de los cinco *folds*, lo cual es fundamental para asegurar la generalización

clínica. El modelo XG Boost es el más estable en rendimiento general, presentando la STD de AUC más baja (0.0324), lo que indica que su poder discriminatorio es altamente consistente.

En contraste, la Regresión Logística (0.0543) muestra la mayor STD de AUC, sugiriendo que su rendimiento general es más sensible a las variaciones en el *dataset*.

Toma de decisiones bajo el Contexto Clínico: Estabilidad en la Detección (Recall Mean y Std) de tumores en fibras nerviosas

Para una patología como la Neurofibromatosis, donde la no detección del riesgo de tumor (un Falso Negativo) puede tener consecuencias catastróficas de vida o muerte, el Recall es la métrica de máxima importancia clínica.

A) **Máxima Detección (Recall Mean):** La Regresión Logística (RL) es el modelo con mayor capacidad de detección, alcanzando un Recall Mean de 0.9846, lo que significa que identifica correctamente casi la totalidad de los casos de alto riesgo. XG Boost (0.8923), a pesar de su alta precisión general, presenta el Recall más bajo, indicando que dejaría escapar a un mayor porcentaje de pacientes con tumor.

B) **Estabilidad Crítica (STD de Recall):** La RL no solo tiene el Recall más alto, sino que también exhibe la mínima desviación estándar en Recall. Esto demuestra que la capacidad de la Regresión Logística para identificar casos de tumor es excepcionalmente estable y confiable a través de las diferentes particiones de los datos.

Entonces, la tabla muestra un dilema de ingeniería: XGBoost es el modelo más estable en AUC (discriminación general), pero la Regresión Logística es la más estable en Recall (detección de alto riesgo).

17

Ante el imperativo ético y clínico de minimizar Falsos Negativos, la elección de la Regresión Logística se justifica por su estabilidad casi perfecta en la detección de casos positivos (STD de Recall=0.0344\$), asegurando que se cumple el objetivo primordial del proyecto: la confiabilidad y la seguridad en la estratificación de riesgo tumoral para pacientes con NF.

Tabulación



- **Análisis del Poder Discriminatorio (AUC Mean)**

Los resultados son, en general, sobresalientes. El valor del **AUC Mean** para los tres modelos se concentra en el rango de 0.94, indicando que la implementación de ingeniería de características fue altamente efectiva.

- **XG Boost (AUC Mean: 0.9449):** Presenta el mejor rendimiento promedio, confirmando su capacidad como líder en modelos de *boosting*.
- **Regresión Logística (AUC Mean: 0.9437):** Es impresionante que un modelo lineal tan simple logre un rendimiento casi idéntico al *boosting*, lo que sugiere que las relaciones subyacentes entre las *features* clínicas y el riesgo de tumor son, en gran medida, separables linealmente.

La escasa diferencia entre los promedios (solo 0.0012 entre XG Boost y RL) nos obliga a mover el enfoque del rendimiento al factor más crítico e importante en investigación clínica y sobre todo, en medicina: la confiabilidad de las herramientas y tecnologías usadas.



2. Discusión de Estabilidad (Desviación Estándar, σ)

Aquí se establece el verdadero valor del proyecto, evaluando el Compromiso Sesgo/Varianza en la aplicación clínica.

A. Estabilidad del AUC - STD (Discriminación General)



Interpretación clínica para Neurofibromatosis tipo NF1:

- *XG Boost* es el modelo con **máxima estabilidad general** (AUC_Std), su varianza es la más baja del conjunto, garantizando que el modelo mantendrá un alto poder discriminatorio ($AUC = 0.94$) incluso si se enfrenta a nuevos grupos o datos de pacientes desconocidos en el entrenamiento.
- *Random Forest (RF)* también es un excelente modelo, el cual presenta una **varianza controlada ligeramente superior a la de XG Boost.**
- *Regresión Logística (RL)*: es el **modelo con la varianza más alta, el rendimiento de este modelo es más susceptible a las variaciones** de los datos durante el *fold*.

B. Estabilidad del Recall (Detección de Alto Riesgo):

El Recall es la métrica de máxima importancia clínica en la NF de tipo F1, ya que mide la capacidad de identificar correctamente a todos los pacientes con

riesgo de tumor en donde la detección de Falsos Negativos ($FN = 0$) es fundamental para un correcto diagnóstico.

- Regresión Logística (LR): es uno de los métodos con los resultados más sorprendentes debido al promedio de Recall (0.9846) y a la desviación estándar baja (0.0344), las cuales indican una confiabilidad absoluta a nivel de detección. La LR es casi perfecta, y el bajo nivel de recall garantiza que su capacidad se mantendrá estable en futuros escenarios de trabajo.
- XG Boost: Con un recall de (0.8923) y una desviación estándar de (0.087) este modelo es menos sensible a las variables y, probablemente fallaría al detectar a un número grande de pacientes con tumores, incrementando el nivel de riesgo de Falsos Negativos.

Conclusiones y Justificación de la Selección Final:

El desarrollo de este *pipeline* no solo responde a un requisito académico, sino a una profunda convicción de que los datos clínicos pueden y deben ser utilizados para mejorar el pronóstico y la calidad de vida de los pacientes de NF tipo NF1 en el mundo.

La capacidad de identificar el riesgo de tumor de manera estable y temprana (demostrada por el recall de la RL) es un paso transformador hacia la medicina personalizada en esta patología. De la mano de la tecnología, la ciencia médica busca obtener nuevas herramientas para realizar sus labores con mayor precisión.

21

Por tanto, este estudio tiene un **potencial clínico y de investigación extraordinario** para la Neurofibromatosis (NF), ya que se diseñó con el objetivo de ser una herramienta de estratificación de riesgo objetiva que aborda el desafío más crítico en el manejo de la NF: **la anticipación de complicaciones severas.**

De acuerdo con los resultados, el modelo permite clasificar a los pacientes de NF1 en

grupos de riesgo (Alto/Bajo) de desarrollar una **complicación tumoral severa** (**Tumour_Case**) utilizando datos clínicos de rutina.

Actualmente, el seguimiento de la NF requiere recursos intensivos y costosos, incrementando las desigualdades económicas de acceso a la salud (ej., resonancias magnéticas frecuentes, medicamentos costosos, consultas clínicas con especialistas, poca oferta de salud pública especializada) para todos los pacientes.

Con este modelo, los pacientes clasificados con **Alto Riesgo** por la RL pueden ser dirigidos a un seguimiento más estricto y directo, que incluye imágenes o pruebas de diagnóstico más frecuentes, mientras que los pacientes clasificados con **Bajo Riesgo** pueden ser monitoreados con menos frecuencia, **reduciendo la carga económica y emocional** sobre el paciente y optimizando el uso de recursos hospitalarios.

Desde una perspectiva técnica, el proceso de *Feature Engineering* proporciona un valor técnico a la investigación. Los factores clínicos que resultaron ser predictivos (y que pasaron el doble filtro LASSO/RF y el chequeo de no-colinealidad) son validados como **variables esenciales** en la patogénesis del riesgo de tumor.

Esto puede guiar a los investigadores a enfocar estudios futuros en la interacción de esos síntomas específicos, además, el modelo podría usarse para **estratificar pacientes** en ensayos clínicos (por ejemplo, para nuevos tratamientos contra tumores en NF). Con este tipo de investigaciones es posible asegurar que los grupos de estudio sean homogéneos en términos de riesgo, lo que aumenta la validez de los resultados del ensayo.

En resumen, este estudio ofrece una herramienta confiable y estable, justificada por la rigurosa técnica de Validación Cruzada Estratificada, que transforma los datos clínicos complejos en una **probabilidad de riesgo accionable** para mejorar el pronóstico de los pacientes con NF de tipo NF1.



Justificación de la elección del modelo (LR)

La Regresión Logística (RL) es un modelo lineal y paramétrico, éstas características lo convierten en una herramienta inherentemente robusta y excelente para la

generalización en entornos clínicos. Su principal fortaleza reside en su bajo riesgo de varianza (sobreajuste), lo que implica una **alta capacidad de generalización más allá del set de datos de entrenamiento**.

Al modelar únicamente la relación lineal entre las variables clínicas y el riesgo de tumor, la RL evitó capturar el ruido o las complejidades específicas de los datos de entrenamiento que modelos más complejos como XG Boost o Random Forest podrían aprender. Esta simplicidad es un filtro, que forza al modelo a enfocarse solo en las relaciones causales más fuertes y esenciales.

Entonces, aunque RL presentó una desviación estándar bajo la curva ligeramente más alta que XGBoost, su naturaleza lineal fue clave. RL logró un Recall Mean de 0.9846 con la mínima desviación estándar de Recall de 0.0344. Este valor mínimo confirma que su capacidad de detección de pacientes de alto riesgo es excepcionalmente estable y no varió significativamente entre los folds.

En esencia, la RL ofrece la solución más confiable y transportable para la detección de alto riesgo, ya que su bajo riesgo de sobreajuste garantiza que sus predicciones se mantendrán consistentes cuando se apliquen a nuevos pacientes de NF que la clínica vea en el futuro.

Referencias

Sharafi, P., Arslan, H., Ersoy, S., Varan, A., & Ayter, Ş. (2025). Neurofibromatosis Type 1; Clinical Symptoms of Familial and Sporadic Cases [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.5505/TurkHijyen.2025.06337>.

Sharafi, P., Arslan, H., Ersoy Evans, S., Varan, A. y Ayter, Ş. (2025). Un enfoque de aprendizaje automático para predecir casos de enfermedades familiares y esporádicas basado en síntomas clínicos: introducción de un nuevo conjunto de datos. *Boletín Turco de Higiene y Biología Experimental*.